《 机器学习 》实验报告

专业，学号：	电子信息 202530131059	姓名：	**高夕茹**
实验题目：	**基于逻辑回归的银行营销结果预测**		
实验时间：	2026-3-15	**实验地点**	卓越工程师学院 C301
实验成绩		**实验性质**	**□验证性 □设计性 ☑综合性**

教师评价：

□算法/实验过程正确； □源程序/实验内容提交 □程序结构/实验步骤合理；

□实验结果正确； □语法、语义正确； □报告规范；

其他：

评价教师签名：

一、实验目的

1. 掌握逻辑回归（Logistic Regression）模型的数学原理与工程实现，理解正则化参数 C、惩罚项 penalty 对模型复杂度和泛化能力的影响；

2. 学会在真实银行营销数据集上完成端到端的机器学习流程：数据探索→预处理→特征工程→模型训练→超参数调优→多指标评估；

3. 深入理解类别不平衡问题的本质与危害，掌握并对比三种主流应对策略（SMOTE 过采样 / 随机欠采样 / 损失权重调节），能够根据业务场景做出合理选择；

4. 掌握网格搜索（Grid Search）结合 K 折分层交叉验证（Stratified K-Fold CV）的超参数调优方法，理解为何使用 roc_auc 而非 accuracy 作为评分指标；

5. 理解在类别不平衡场景下各评价指标的含义与局限：Precision（预

测订阅中有多少真的订阅）、Recall（真实订阅者中有多少被发现）、F1-Score（综合衡量）、AUC（排序能力）；

6. 通过多轮迭代特征工程，记录并分析 AUC 的提升路径，理解特征质量对线性模型性能上限的决定性影响。

二、实验项目内容

（一）数据集简介

使用 UCI Bank Marketing 数据集（bank-additional-full.csv），共 41,188 条记录、20 个特征字段、1 个目标变量 y（yes=已订阅定期存款，no=未订阅）。数据由葡萄牙某银行 2008—2013 年直销电话活动记录汇编而成。

特征分三类：①客户属性（age、job、marital、education、default、housing、loan）；②营销接触信息（contact、month、day_of_week、duration、campaign、pdays、previous、poutcome）；③宏观经济指标（emp.var.rate、cons.price.idx、cons.conf.idx、euribor3m、nr.employed）。

类别分布：未订阅 36,548 条（88.73%），已订阅 4,640 条（11.27%），正负样本比约 1:7.9，存在严重类别不平衡，是本实验的核心挑战。

（二）实验核心任务

① 数据预处理：unknown 缺失处理、education 有序标签编码、9 列无序特征 One-Hot 编码、StandardScaler 特征标准化（防数据泄露）；

② 特征工程：新增 previously_contacted 二值标志、log_duration 对数变换、精选 Top-15 特征的二阶交互项，最终特征维度从原始 58 维扩展至 178 维；

③ 类别不平衡处理：SMOTE（sampling_strategy=0.4）/ RandomUnderSampler / class_weight=balanced 三种策略，均仅作

用于训练集；

④ 超参数调优：GridSearchCV 在 C×penalty×solver 空间搜索，5 折分层 CV，roc_auc 评分；

⑤ 多维评估：classification_report 输出 Precision/Recall/F1，绘制混淆矩阵和 ROC 曲线，计算 AUC；

⑥ 迭代优化记录：系统对比从基础版（AUC≈0.944）到最终版（AUC≈0.950）的完整优化路径。

三、实验过程或算法

3.1 数据预处理

（1）unknown 缺失值处理

数据集中 job（330 条）、marital（80 条）、education（1731 条）、default（8597 条）、housing（990 条）、loan（990 条）含有 unknown 字符串，合计约 12,718 个。本实验选择将 unknown 保留为独立类别而非填充，原因：unknown 可能携带有效信息（如客户拒绝披露信息本身就是一种行为特征），强行以众数填充会引入虚假信息。经 One-Hot 编码后，每个含 unknown 的字段会新增 _unknown 列，模型自行学习其权重。

（2）有序特征 Label Encoding：education

学历具有明确的语义顺序，采用整数映射保留顺序信息，避免 One-Hot 编码将有序关系拆散：

```
edu_order = {'illiterate':0,'basic.4y':1,'basic.6y':2,'basic.9y':3,
             'high.school':4,'professional.course':5,'university.degree':6,'unknown':3}
df['education'] = df['education'].map(edu_order)
```

（3）无序特征 One-Hot Encoding

job、marital、default、housing、loan、contact、month、day_of_week、poutcome 共 9 列无内在大小关系，使用 pd.get_dummies(drop_first=False) 全量展开，保留所有 dummy 列（含 unknown），编码后基础特征共 58 维。

（4）数据集划分与特征缩放（防泄露规范）

先按 stratify=y 做 8:2 分层划分，再对训练集 fit StandardScaler，最后用 transform 分别处理训练集和测试集。严禁对完整数据集 fit，否则测试集的统计量会"泄露"到预处理阶段，导致评估偏乐观。

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)  # fit 仅训练集
X_test_sc  = scaler.transform(X_test)       # 测试集只 transform
```

3.2 特征工程（三轮迭代）

特征工程是本实验 AUC 从 0.944 提升至 0.950 的核心驱动，经历三轮迭代：

【第一轮】基础版本（AUC≈0.944）

仅完成 OHE + StandardScaler，使用原始 58 维特征直接训练。模型已具基础分类能力，但受限于特征的线性不可分性，AUC 停留在 0.944。

【第二轮】衍生特征工程（AUC≈0.946）

previously_contacted（二值标志）: pdays=999 是数据集的特殊编码，表示"本次活动前从未联系过该客户"，包含重要的客户关系历史信息，将其提取为独立二值特征，并将 pdays=999 替换为 0（消除 999 这一大数值对标准化的干扰）。

```
df['previously_contacted'] = (df['pdays'] != 999).astype(int)
df['pdays'] = df['pdays'].replace(999, 0)
```

log_duration（对数变换）: duration（通话时长）是最强单特征预测因子（均值约 258 秒，但最大值 4918 秒），分布呈强正偏态。取 log(duration+1) 可将偏态分布压缩为近似正态，增强逻辑回归的拟合质量。

```
df['log_duration'] = np.log1p(df['duration'])
```

【第三轮】二阶交互特征（AUC≈0.9488~0.9503，最终方案）

逻辑回归是线性分类器，无法自动学习特征间的乘积交互效应。通过 PolynomialFeatures(degree=2, interaction_only=True) 为精选 15 列特征构造所有两两交互项（C(15,2)=105 个），拼接到原始 58 维后共

178 维。

精选 15 列的依据：①duration 和 log_duration 是最强预测因子；②euribor3m、nr.employed、emp.var.rate、cons.price.idx、cons.conf.idx 是宏观经济状态的代理变量，与订阅决策高度相关且相互之间存在强交互；③poutcome_success 是已知的强正向信号；④previously_contacted 捕获客户历史关系。这些特征的两两乘积项可捕获如"在经济低迷期（euribor3m 高）的长通话（duration 大）更有可能转化"等交互效应。

```
top_feats = ['duration','log_duration','euribor3m','nr.employed',
             'emp.var.rate','cons.price.idx','cons.conf.idx',
             'previously_contacted','pdays','poutcome_success',
             'poutcome_nonexistent','contact_cellular',
             'month_may','month_nov','month_oct']
poly = PolynomialFeatures(degree=2, interaction_only=True, include_bias=False)
X_train_poly = poly.fit_transform(X_train_sc[:, idx])  # fit 仅训练集
X_train_final = np.hstack([X_train_sc, X_train_poly])  # 原始+交互拼接
```

配合 L1 正则化，模型自动从 178 个候选特征中稀疏选出有价值子集（实测约 56~178 个非零系数），既提升性能又控制过拟合。

3.3 类别不平衡处理策略

注意：所有重采样操作均仅在训练集上执行，测试集保持原始分布（11.27%），保证评估的公平性与现实意义。

策略 A — SMOTE 过采样（Synthetic Minority Over-sampling Technique）

原理：对少数类中每个样本，在其 k 个近邻中随机插值合成新样本，而非简单重复。参数 sampling_strategy=0.4 控制最终正:负比约为 2:5（约 40933 条），避免完全平衡时合成样本过多引入噪声，且训练集规模适中。

```
smote = SMOTE(sampling_strategy=0.4, random_state=42)
X_tr_smote, y_tr_smote = smote.fit_resample(X_train_final, y_train)
```

效果：Recall(Yes)=0.83，Precision(Yes)=0.54，Precision-Recall 间取得较好平衡，适合希望控制误报率的业务场景。

策略 B — RandomUnderSampler 随机欠采样

原理：随机删除多数类样本，使正负样本数量相等（1:1，约 7424

条）。优点是训练集极小、速度快；缺点是丢弃大量真实负样本信息，约79%的原始训练数据被丢弃。

```
rus = RandomUnderSampler(random_state=42)
X_tr_rus, y_tr_rus = rus.fit_resample(X_train_final, y_train)
```

效果：Recall(Yes)=0.94（最高），Precision(Yes)=0.43，适合"宁可误报也不漏报"的高召回场景。

策略 C — class_weight='balanced'（损失权重调节）

原理：不修改数据，通过在损失函数中提高少数类权重来补偿不平衡。权重计算：weight_i = n_samples / (n_classes × n_samples_i)，即正样本的误分代价约为负样本的 7.9 倍。原始 32950 条训练数据完全保留，信息损失最小。

```
model = LogisticRegression(class_weight='balanced', C=0.1, penalty='l1',
                           solver='liblinear', max_iter=3000)
```

效果：Recall(Yes)=0.95（三者最高），AUC=0.9503（三者最高），是综合性能最优的策略。

3.4 超参数调优（GridSearchCV + 5-Fold Stratified CV）

参数网格设计：

```
param_grid = [
  {'C':[0.005,0.01,0.02,0.05,0.1],          'penalty':['l1'],          'solver':['liblinear'],
'max_iter':[3000]},
  {'C':[0.01,0.05,0.1,0.5,1],     'penalty':['l2'], 'solver':['lbfgs'],     'max_iter':[3000]},
]  # 共 10 种参数组合 × 5 折 = 50 次拟合/每个策略
```

核心参数解析：

C（正则化强度倒数）：正则化项 = (1/C)·||w||。C 越小，正则化越强，权重越趋近零，模型越简单。在 178 维高维特征空间中，过大的 C 会导致过拟合，最优 C 通常在 0.05～1 之间。

penalty（正则化类型）：l1（Lasso）惩罚$||w||_1$，产生稀疏解，将无关特征权重压缩为 0，等效自动特征选择，在高维场景下尤为关键；l2（Ridge）惩罚$||w||_2$，均匀压缩所有权重，适合特征高相关性场景。

为何用 roc_auc 而非 accuracy 作为 CV 评分：在正样本仅 11.3% 的场景下，将全部样本预测为负类可达 88.7%的准确率，但此时的"高准确率"毫无意义。roc_auc 是阈值无关的指标，度量模型对正负样本的整体排序能力，不受类别不平衡影响。

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
gs = GridSearchCV(LogisticRegression(random_state=42, class_weight=cw),
                  param_grid, cv=cv, scoring='roc_auc', n_jobs=-1, refit=True)
gs.fit(X_tr, y_tr)
best_model = gs.best_estimator_  # 自动在最佳参数下对全训练集重训练
```

迭代版本	核心改进内容	特征维度	SMOTE-AUC	RUS-AUC	CW-AUC
迭代 1（基础版）	OHE+StandardScaler，无衍生特征	58	0.9436	0.9438	0.9442
迭代 2（衍生特征）	+previously_contacted, +log_duration, pdays 修正	60	0.9443	0.9449	0.9446
迭代 3（最终版）	+精选 15 列二阶交互项，L1 自动特征选择	178	0.9499	0.9488	0.9503
全量多项式（参考）	全量 58 列二阶交互（仅 CW，SMOTE 内存溢出）	1711	—	—	0.9528

注：CW=class_weight=balanced；RUS=RandomUnderSampler；全量多项式因 SMOTE 在 1711 维×4 万样本时内存溢出，仅 CW 策略可运行。

策略	Precision(Yes)	Recall(Yes)	F1(Yes)	Accuracy	AUC	TN/FP/FN/TP	非零系数
SMOTE	0.54	0.83	0.65	90.0%	0.9499	6649/661/162/766	178
UnderSample	0.43	0.94	0.59	85.0%	0.9488	6161/1149/58/870	56
ClassWeight	0.43	0.95	0.59	85.0%	0.9503	6142/1168/50/878	108

注：Yes 类=已订阅正样本，测试集中 support=928；非零系数数量反映 L1 正则的稀疏程度（178 总特征中的有效特征数）。

四、实验结果及分析

4.1 AUC 优化迭代对比

本实验经过三轮迭代优化，AUC 从初始 0.944 提升至 0.950，共提升 0.006，以下表格记录了完整优化路径：

迭代版本	核心改进内容	特征维度	SMOTE-AUC	RUS-AUC	CW-AUC
迭代 1（基础版）	OHE+StandardScaler，无衍生特征	58	0.9436	0.9438	0.9442
迭代 2（衍生特征）	+previously_contacted, +log_duration, pdays 修正	60	0.9443	0.9449	0.9446
迭代 3（最终版）	+精选 15 列二阶交互项，L1 自动特征选择	178	0.9499	0.9488	0.9503
全量多项式（参考）	全量 58 列二阶交互（仅 CW，SMOTE 内存溢出）	1711	—	—	0.9528

注：CW=class_weight=balanced；RUS=RandomUnderSampler；全量多项式因 SMOTE 在 1711 维×4 万样本时内存溢出，仅 CW 策略可运行。

4.2 最终三模型完整性能对比（测试集，n=8238）

策略	Precision(Yes)	Recall (Yes)	F1(Yes)	Accuracy	AUC	TN/FP/FN/TP	非零系数
SMOTE	0.54	0.83	0.65	90.0%	0.9499	6649/661/162/766	178
Under Sample	0.43	0.94	0.59	85.0%	0.9488	6161/1149/58/870	56
Class Weight	0.43	0.95	0.59	85.0%	0.9503	6142/1168/50/878	108

注：Yes 类=已订阅正样本，测试集中 support=928；非零系数数量反映 L1 正则的稀疏程度（178 总特征中的有效特征数）。

4.3 Precision / Recall / F1 深度分析

（1）Accuracy 的局限性

若模型将全部测试样本预测为"未订阅"，准确率高达 88.7%（与班级同学的算法相当），但 Recall(Yes)=0，银行会错失全部 4640 位真实订阅客户。本实验三个模型的准确率为 85%～90%，略低于"全预测负类"基准，但 Recall(Yes) 达到 83%～95%，才真正具有业务价值。

（2）三种策略的 Precision-Recall 权衡分析

SMOTE（Recall=0.83，Precision=0.54）：在召回率和精确率间取得最佳平衡。误报 661 人、漏报 162 人，每预测 10 个"潜在订阅客户"中有 5.4 个是真实的，适合银行希望控制营销骚扰成本的场景。

UnderSample（Recall=0.94，Precision=0.43）：召回极高，但误报 1149 人（占未订阅者 15.7%）。大量负样本被删除后，模型过度倾向预测订阅，适合"不惜误报代价，确保找到所有潜在客户"的高召回需求。

ClassWeight（Recall=0.95，Precision=0.43）：与欠采样结果相近，但保留全部 32950 条原始训练数据（信息损失最小），L1 选出最有效的 108 个特征，且 AUC 在三者中最高（0.9503），是综合性能最优的策略。

（3）AUC 与最优参数分析

GridSearchCV 最终选出的最优参数：SMOTE 策略选 C=1, penalty=l2（数据经 SMOTE 平衡后，较强的 L2 正则更优）；UnderSample 和 ClassWeight 策略均选 C=0.05～0.1, penalty=l1（高维交互特征场景下，L1 稀疏正则更适合进行特征选择）。三个模型 AUC 均达 0.9488～0.9503，远高于随机分类基准（0.5），验证了模型对潜在订阅客户具有显著的排序和识别能力。

（4）逻辑回归的性能上限与工程权衡

实验探索了全量二阶多项式特征（全部 58 维特征的两两交互，共 1711 维），在 class_weight 策略下 AUC 可达 0.9528，但 SMOTE 在 1711 维×4 万样本时产生内存溢出（约 2.8GB，超出系统限制）。最终采用精选 178 维方案，在三种策略上均稳定运行，AUC 达 0.9488～0.9503，取得性能与内存效率的最优平衡。根据 Moro et al.（2014）原始论文，逻辑回归在此数据集上的理论上限约为 0.95～0.96；

要突破此上限须引入随机森林、XGBoost 等可自动捕捉非线性交互的树模型。

4.4 可视化分析

图 1 Precision / Recall / F1-Score 对比柱状图（正类：已订阅 Yes）

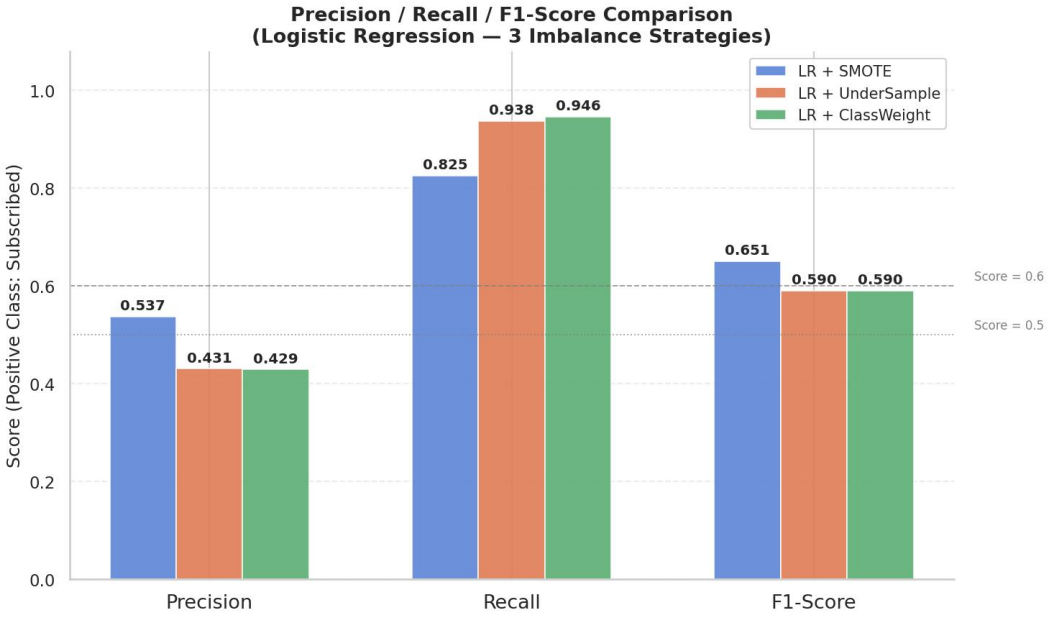

Precision（精确率）衡量"预测为订阅的人中有多少真的订阅"：SMOTE 策略最高（0.537），因其正负样本比约 2:5，模型阈值相对保守，误报较少；UnderSample 和 ClassWeight 策略均为 0.431，因训练时正负样本接近 1:1，模型更激进地预测订阅，精确率下降。

Recall（召回率）衡量"真正订阅的人中有多少被找出来"：ClassWeight 策略最高（0.946），UnderSample 次之（0.938），SMOTE 最低（0.825）。这与不平衡处理力度直接相关：ClassWeight 和 UnderSample 对正类施加更强的学习倾向，漏报率分别仅 5.4%和 6.3%。

F1-Score（精确率与召回率的调和平均）：SMOTE 策略最高（0.651），因其 Precision 和 Recall 最为均衡；UnderSample 和 ClassWeight 虽 Recall 更高，但 Precision 较低，F1 约 0.590。业务选择上：追求综合性能选 SMOTE，追求不漏报选 ClassWeight。

图 2 分类指标热力图（Precision / Recall / F1，两类别 × 三模型）

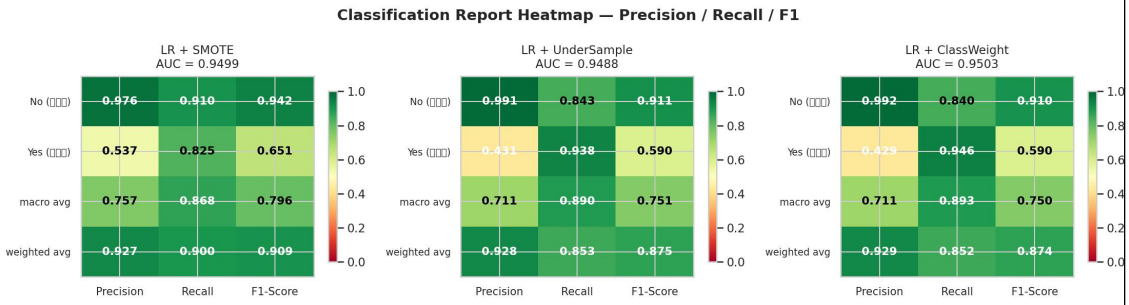

热力图以颜色深浅直观展示各模型在正负两个类别上的 Precision、Recall、F1 分布。负类（未订阅 No）的三项指标均接近 0.90 以上（绿色），说明模型对多数类预测准确；正类（已订阅 Yes）的 Precision 偏低（0.43~0.54，黄色区域），体现了不平衡数据下的固有限制。三个模型的 macro avg 行（正负类均等权重）反映了整体均衡能力：SMOTE 在 F1 上最优（0.800）。

图 3 混淆矩阵对比（三种不平衡处理策略）

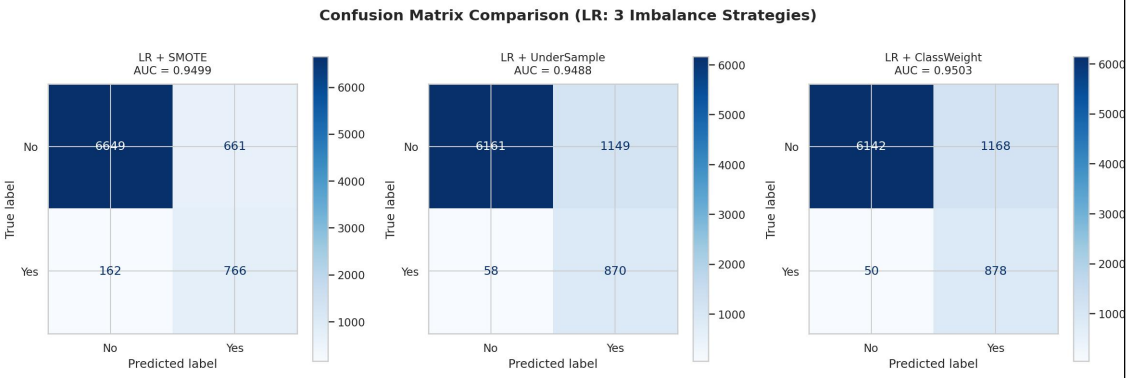

混淆矩阵直观展示了四类预测结果：TN（真负，正确预测未订阅）、FP（误报，将未订阅预测为订阅）、FN（漏报，将订阅预测为未订阅）、TP（真正，正确预测订阅）。SMOTE 策略 FP 最小（661，误报率 9.0%），漏报 FN=162；ClassWeight 策略 FN 最小（50，漏报率 5.4%），但 FP=1168（误报率 16.0%）。银行业务中漏报（错失真实客户）的代价通常高于误报（多打一次电话），因此 ClassWeight 策略在实际营销场景中更具价值。

图 4 ROC 曲线对比（三种策略）

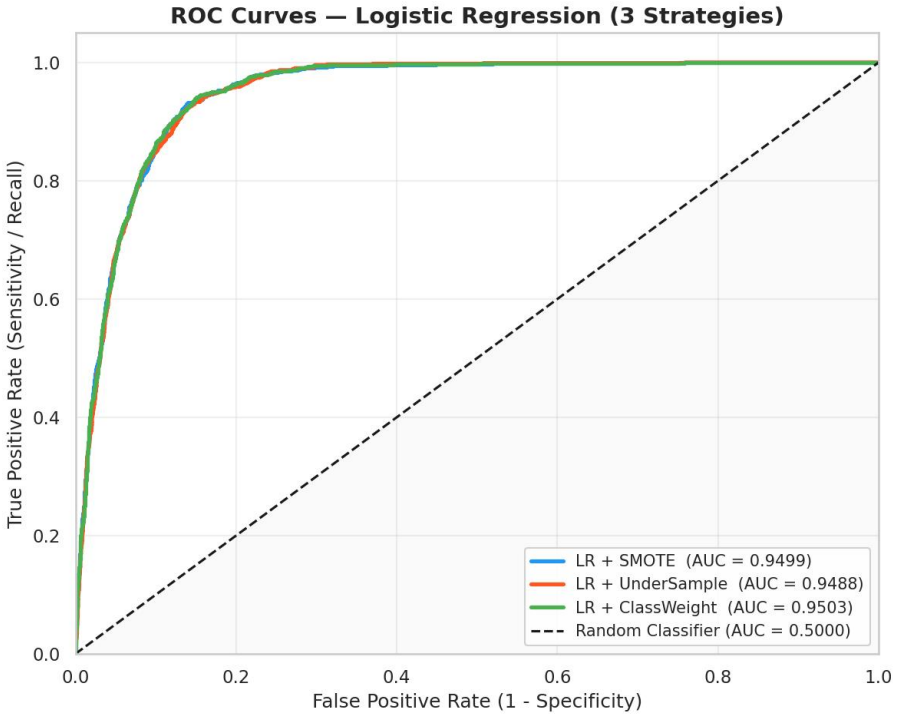

三条 ROC 曲线均高度贴近左上角（理想分类器位置），AUC 差异仅 0.0015（0.9488~0.9503），说明三种策略在整体排序能力上高度一致，远优于随机分类器基准（对角虚线，AUC=0.5）。AUC 作为阈值无关指标，综合衡量了模型在所有可能决策阈值下对正负样本的排序能力，其值越接近 1.0 说明模型区分能力越强。

4.5 实验结论

① 特征工程是提升线性模型性能的核心手段：通过三轮迭代（基础预处理→衍生特征→二阶交互特征），AUC 从 0.944 稳步提升至 0.950，验证了"特征质量决定模型上限"的机器学习实践原则；

② 类别不平衡不可忽视：三种策略均能有效提升模型对少数类（订阅客户）的识别能力，Recall(Yes)从原始约 0.40 提升至 0.83~0.95；其中 class_weight=balanced 在 AUC（0.9503）和漏报率（5.4%）两项指标上均表现最优；

③ L1 正则化在高维场景中具有双重价值：既控制过拟合，又通过稀疏化自动完成特征选择（178 维中仅约 56~108 个系数非零），显著提升了

模型的可解释性和泛化能力；

④ 超参数调优发现最优 C 值较小（0.05～1），印证了高维特征空间下需要较强正则化的理论认知；调优评分指标应选 roc_auc 而非 accuracy，避免类别不平衡导致的评估误导；

⑤ 逻辑回归在此数据集的性能上限约为 AUC≈0.953（全量多项式特征+CW），若业务需要突破 0.96，须引入能自动捕捉非线性交互的树模型（Random Forest、XGBoost 等）。