《 机器学习 》实验报告

专业，学号：	电子信息 202530131051		姓名：	**张硕钦**
实验题目：	**基于逻辑回归的银行营销结果预测**			
实验时间：	2026-3-15	**实验地点**	卓越工程师学院 C202	
实验成绩		**实验性质**	**□验证性 □设计性 ☑综合性**	

教师评价：

□算法/实验过程正确； □源程序/实验内容提交 □程序结构/实验步骤合理；

□实验结果正确； □语法、语义正确； □报告规范；

其他：

评价教师签名：

一、实验目的

1. 深入理解逻辑回归（Logistic Regression）的数学原理：掌握 Sigmoid 激活、对数似然损失函数、正则化项（L1/L2）的作用机制，以及超参数 C、penalty 对模型复杂度与泛化能力的影响；

2. 掌握工程化的端到端机器学习流程：从数据探索、预处理、多轮迭代特征工程，到超参数调优、多维评估，以 6 个解耦模块（config / preprocessing / imbalance / modeling / evaluation / main）构建可维护的项目结构；

3. 深入理解类别不平衡问题的危害与应对策略：对比 SMOTE 过采样、随机欠采样、损失权重调节三种方案，理解其在 Precision-Recall 权衡上的本质差异，能根据业务需求（控误报 vs. 控漏报）进行合理选择；

4. 掌握 GridSearchCV + K 折分层交叉验证的超参数调优方法，理解为何在不平衡数据集上必须以 roc_auc 而非 accuracy 作为评分指标；

5. 理解并会计算类别不平衡场景下的核心评估指标：Precision（精确率）、Recall（召回率）、F1-Score（调和平均）、ROC-AUC（排序能力），并能从混淆矩阵中解读 FP（误报）与 FN（漏报）的业务含义；

6. 通过四轮迭代特征工程（基础 OHE → 衍生特征 → 多项式交互 → QuantileTransformer 归一化），记录 AUC 的完整提升路径，深刻理解"特征质量决定线性模型性能上限"的核心工程原则；

7. 理解逻辑回归在结构化数据集上的性能边界：通过与 GradientBoosting 的对比实验，认识到线性模型在面对非线性决策边界时的固有局限，并了解突破该局限所需的模型改进方向。

二、实验项目内容

（一）数据集简介

使用 UCI Bank Marketing 完整数据集（bank-additional-full.csv），共 41,188 条葡萄牙银行电话营销记录（2008—2013 年），20 个特征字段，目标变量 y 为客户是否订阅定期存款（yes/no）。

特征分三类：① 客户基本属性（age、job、marital、education、default、housing、loan）；② 本次营销接触信息（contact、month、day_of_week、duration、campaign、pdays、previous、poutcome）；③ 宏观经济指标（emp.var.rate、cons.price.idx、cons.conf.idx、euribor3m、nr.employed）。

类别分布严重不平衡：未订阅 36,548 条（88.73%）、已订阅 4,640 条（11.27%），正负样本比约 1:7.9；此外约 12,718 个字段含 unknown 缺失标记，属于真实工业数据的典型噪声。

（二）工程化项目架构

本实验将功能解耦为 6 个独立模块，提升可读性与可复现性：

模块文件	职责说明
config.py	全局配置：路径、随机种子、CV 折数、超参数网格、多项式特征列表
preprocessing.py	数据加载→特征工程→编码→QuantileTransformer

	归一化→多项式展开
imbalance.py	三种不平衡处理策略封装（SMOTE / 欠采样 / class_weight 标志）
modeling.py	GridSearchCV + StratifiedKFold 超参数搜索，返回最优模型
evaluation.py	测试集推断、分类报告打印、混淆矩阵与 ROC 曲线绘图、AUC 汇总
main.py	主执行入口，串联上述 5 个模块的完整流水线

（三）实验核心任务

① 数据预处理：unknown 作为独立类别保留、education 有序 Label Encoding、9 列无序特征 One-Hot Encoding、pdays=999 替换为 0 并生成二值指示符；

② 四轮迭代特征工程：从基础 58 维到最终 495 维，AUC 从 0.9440 稳步提升至 0.9520；

③ 分布归一化升级：以 QuantileTransformer（输出正态分布）替换 StandardScaler，显著改善偏斜特征对 L1 梯度的干扰；

④ 类别不平衡处理：SMOTE（sampling_strategy=0.4）/ RandomUnderSampler / class_weight='balanced'，所有重采样仅作用于训练集；

⑤ 超参数调优：GridSearchCV 在 C×penalty 空间搜索，3 折分层 CV，roc_auc 评分，共 8 种组合 × 3 折 = 24 次拟合/策略；

⑥ 多维评估：classification_report 输出 Precision/Recall/F1、指标分组柱状图可视化、混淆矩阵、ROC 曲线 + AUC；

⑦ 基准对比实验：与 GradientBoosting（sklearn 默认参数）对比，验证 LR 性能上限。

三、实验过程或算法

3.0 逻辑回归数学原理

（1）Sigmoid 函数与预测概率

逻辑回归将线性函数的输出通过 Sigmoid 函数映射为 [0,1] 范围内的概率值，以衡量样本属于正类的可能性：

$$P(y=1 \mid x) = \sigma(w^T x + b) = 1 / (1 + \exp(-(w^T x + b)))$$

其中 w 为权重向量，b 为偏置，x 为特征向量。当 P > 0.5 时预测为正类（订阅），否则为负类（不订阅）。

（2）对数似然损失函数（Log Loss）

逻辑回归通过最大化对数似然（等价于最小化交叉熵损失）来训练模型：

$$L(w, b) = -(1/n) \Sigma_i [y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)]$$

该函数对"自信但错误"的预测施以更大惩罚，使模型在不平衡数据中倾向于多数类——这正是类别不平衡需要专门处理的根源。

（3）正则化目标函数

为防止高维特征（495 维）过拟合，在损失函数中加入正则化惩罚项，sklearn 中以参数 C（正则化强度倒数）控制：

$$J(w) = L(w, b) + (1/C) \cdot \Omega(w)$$

L1 正则化（penalty='l1'）: $\Omega(w) = ||w||_1 = \Sigma|w_i|$，产生稀疏解，将不相关特征权重精确压缩为 0，适合 495 维高维场景；L2 正则化（penalty='l2'）: $\Omega(w) = ||w||_2^2 = \Sigma w_i^2$，均匀收缩所有权重，适合特征高度相关场景。

$$L1: \Omega(w) = \Sigma_i |w_i|$$
$$L2: \Omega(w) = \Sigma_i w_i^2$$

（4）ROC-AUC 评估原理

ROC 曲线横轴为假阳率 FPR = FP/(FP+TN)，纵轴为真阳率 TPR = TP/(TP+FN)，曲线下面积 AUC 的概率含义为：

$$AUC = P(score(x^+) > score(x^-))$$

AUC=1.0 表示完美区分；AUC=0.5 等同随机猜测。AUC 是阈值无关

的整体排序能力度量，完全不受类别不平衡影响，因此在本实验中作为首要优化目标和 GridSearchCV 评分指标。

3.1 数据预处理

（1）unknown 缺失值处理

数据集中 job（330 条）、marital（80 条）、education（1731 条）、default（8597 条）、housing（990 条）、loan（990 条）含有 unknown，合计约 12,718 个。本实验选择将 unknown 保留为独立类别，而非以众数填充。原因：① unknown 本身可能是有效信息（客户拒绝披露信用违约记录可能恰好是高风险信号）；② 众数填充会引入虚假样本，使分布失真；③ One-Hot 编码后新增 _unknown 列，模型可自行学习其权重。

（2）education 有序 Label Encoding

学历存在明确的认知顺序（文盲→小学→初中→高中→大专→本科），若改用 One-Hot 编码会将该顺序信息拆散，使模型无法利用"学历越高，理财意识可能越强"的单调性。映射方案如下：

```
EDU_ORDER = {'illiterate':0, 'basic.4y':1, 'basic.6y':2, 'basic.9y':3,
             'high.school':4, 'professional.course':5,
             'university.degree':6, 'unknown':3}  # unknown 以中等水平缺省
df['education'] = df['education'].map(EDU_ORDER)
```

（3）无序特征 One-Hot Encoding

job、marital、default、housing、loan、contact、month、day_of_week、poutcome 共 9 列不含内在大小关系，使用 pd.get_dummies(drop_first=False) 全量展开。drop_first=False 保留所有 dummy 列（含 unknown 列），避免因删除参考类而损失信息；编码后基础特征从原始 20 维扩展为 60 维。

（4）数据集分层划分（防信息泄露规范）

按 stratify=y 做 8:2 分层划分，确保训练集（32,950 条）与测试集（8,238 条）的正样本比例一致（均约 11.27%）。所有预处理 Transformer（QuantileTransformer、PolynomialFeatures）均仅在训练集上 fit，再对测试集做 transform，严防统计量泄露。

```
X_train, X_test, y_train, y_test = train_test_split(
```

```
    X, y, test_size=0.2, random_state=42, stratify=y)
qt = QuantileTransformer(output_distribution='normal', n_quantiles=1000)
X_train_sc = qt.fit_transform(X_train)  # fit 仅训练集，防泄露
X_test_sc  = qt.transform(X_test)
```

3.2 特征工程（四轮迭代）

特征工程是本实验 AUC 从 0.9440 提升至 0.9520 的核心驱动力，历经四轮迭代，每轮均记录了 AUC 的变化。

【第一轮】基础版本（AUC ≈ 0.9440）

仅完成 One-Hot + StandardScaler，直接使用原始 58 维特征训练 LR。模型已具备基础分类能力，但 StandardScaler 无法消除 duration（最大值 4918s，强右偏）和 euribor3m 等偏斜分布，梯度不稳定，且模型面对特征间的非线性关系无能为力，AUC 停留在 0.9440。

【第二轮】衍生特征工程（AUC ≈ 0.9478，+0.0038）

新增 4 个手工衍生特征：

pdays_contacted（二值指示符）: pdays=999 是数据集的特殊编码，表示"本次活动前从未联系过客户"，96.3% 的样本为此状态。将其提取为独立二值特征，同时将 pdays=999 替换为 0，消除该极大值对标准化的干扰。

```
df['pdays_contacted'] = (df['pdays'] != 999).astype(int)
df['pdays'] = df['pdays'].replace(999, 0)
```

duration_log（对数变换）: duration 是最强单特征预测因子（单独 AUC=0.818），但呈强正偏态。log(1+x) 将分布压缩为近似正态，使 LR 能更稳定地拟合该非线性效应。

$$\boldsymbol{duration_log = log(1 + duration)}$$

```
df['duration_log'] = np.log1p(df['duration'])
```

econ_pressure（经济压力指标）: emp.var.rate × euribor3m 的乘积捕获就业变动率与利率的联合效应——利率高且就业不稳定时，人们更倾向于储蓄定期存款。

$$\boldsymbol{econ_pressure = emp.var.rate \times euribor3m}$$

prev_success（历史成功标志）: poutcome=='success' 的二值化，是最强的正类预测信号之一（历史上曾成功说服客户订阅的客户再次成功率显著更高）。

【第三轮】多项式特征 + QuantileTransformer（AUC ≈ 0.9509，+0.0031）

① 归一化升级：以 QuantileTransformer(output_distribution='normal') 替换 StandardScaler。StandardScaler 仅做零均值单位方差变换，无法消除偏态分布；QuantileTransformer 通过分位数映射将每个特征变换为标准正态分布，从根本上消除偏斜，使 L1 正则化的近端梯度算法收敛更快、更稳定。实验验证该替换可带来约 +0.003 AUC 提升。

② 首次引入多项式特征（5 个核心特征，75 维）：对 duration_log、emp.var.rate、euribor3m、cons.conf.idx、nr.employed 做 degree=2 全量展开（含平方项），生成 15 个新特征，总维度从 60 升至 75。

```
poly = PolynomialFeatures(degree=2, interaction_only=False, include_bias=False)
X_train_poly = poly.fit_transform(X_train_sc[:, poly_idx])
X_train_final = np.hstack([X_train_sc, X_train_poly])
```

【第四轮】扩展多项式至 29 列（AUC ≈ 0.9520，最终方案，+0.0011）

将多项式展开的特征集从 5 个扩展至 29 列，在原有 13 个连续型特征基础上，新增 16 列关键 One-Hot 二值特征（poutcome_success、contact_cellular、month_may/nov/oct/mar/sep 等）一并纳入多项式展开。设计依据：① poutcome_success × duration_log 是极强信号；② contact_cellular × duration 捕获接触渠道与通话质量的交互；③ 月份 dummy 与经济指标的交互捕获季节性效应。29 个特征的 degree=2 展开生成 435 个新特征项，总维度从 60 升至 495。配合 L1 正则化，模型自动从 495 维中稀疏选出有价值子集。

```
POLY_FEATURES = [
    'duration', 'duration_log', 'euribor3m', 'nr.employed', 'emp.var.rate',
    'cons.price.idx', 'cons.conf.idx', 'pdays_contacted', 'econ_pressure',
    'prev_success', 'previous', 'pdays', 'education',
    'poutcome_success', 'poutcome_nonexistent', 'contact_cellular',
    'month_may', 'month_nov', 'month_oct', 'month_mar', 'month_sep',
    'job_student', 'job_retired', 'marital_single', ...
] # 共 29 列 → degree=2 展开后 495 维总特征
```

3.3 类别不平衡处理策略（三种）

重要原则：所有重采样操作均仅作用于训练集，测试集保持原始分布（11.27% 正样本），确保评估的现实意义和公平性。

策略 A — SMOTE 过采样（Synthetic Minority Over-sampling Technique）

原理：对少数类每个样本，在其 k=5 个近邻间随机线性插值合成新样本；新样本位于特征空间中已有少数类样本的"邻域"内，引入多样性同时保留统计分布。参数 sampling_strategy=0.4 将正样本补充至多数类的 40%（约 40,933 条，正样本占比 28.6%）。选择 0.4 而非 1:1 完全平衡，是因为过度合成会引入大量人工噪声样本，实验验证 0.4 时 AUC 最优。

```
smote = SMOTE(sampling_strategy=0.4, random_state=42, k_neighbors=5)
X_tr_smote, y_tr_smote = smote.fit_resample(X_train_final, y_train)
# 输出：(40933, 495)，正样本占比 28.6%
```

策略 B — RandomUnderSampler 随机欠采样

原理：随机删除多数类样本，使正负样本 1:1 对齐（约 7,424 条），优点是训练集极小速度快；缺点是丢弃 77.5% 的原始训练数据，约 25,526 条真实负样本信息永久损失。适合训练数据量不是瓶颈、更关注召回率的场景。

```
rus = RandomUnderSampler(random_state=42)
X_tr_rus, y_tr_rus = rus.fit_resample(X_train_final, y_train)
# 输出：(7424, 495)，正样本占比 50.0%
```

策略 C — class_weight='balanced'（损失函数权重调节）

原理：不修改任何样本，通过在交叉熵损失中对每个样本的误分代价加权来补偿不平衡。sklearn 的 balanced 模式自动计算各类权重：

$$weight_c = n_samples / (n_classes \times count_c)$$

全部 32,950 条原始训练数据完整保留，是信息损失最小的策略。

```
model = LogisticRegression(class_weight='balanced',
                           C=0.005, penalty='l1', solver='liblinear',
                           max_iter=3000, random_state=42)
```

3.4 超参数调优（GridSearchCV + 3-Fold Stratified CV）

参数网格设计（共 8 种参数组合 × 3 折 = 24 次拟合/策略）：

```
PARAM_GRID = [
   {'penalty':['l1'], 'C':[0.005, 0.01, 0.02, 0.05],
    'solver':['liblinear'], 'max_iter':[3000]},
   {'penalty':['l2'], 'C':[0.005, 0.01, 0.02, 0.05],
    'solver':['lbfgs'], 'max_iter':[3000]},
]
```

C（正则化强度倒数）：LR 目标函数 min (1/C)·||w||_p + L(w)。C 越小，正则化越强，模型越简单。在 495 维高维空间中，实验验证最优 C 集中在 0.005～0.05 的强正则化区间。

penalty（正则化类型）：L1 惩罚 $\Sigma|w_i|$ 产生稀疏解（等效自动特征选择）；L2 惩罚 Σw_i^2 均匀压缩所有权重，适合高度相关特征（宏观经济指标间高共线性）。

选用 roc_auc 评分的必要性：若以 accuracy 作为 CV 评分，将全部样本预测为"未订阅"可获得 88.7% 的准确率，GridSearch 可能错误地选出偏向多数类的参数。roc_auc 是阈值无关的排序指标，完全不受类别不平衡的影响。

```
cv = StratifiedKFold(n_splits=3, shuffle=True, random_state=42)
gs = GridSearchCV(LogisticRegression(random_state=42),
            PARAM_GRID, cv=cv, scoring='roc_auc',
            n_jobs=-1, refit=True)
gs.fit(X_tr, y_tr)  # refit=True: 在最优参数下对全训练集重训练
best_model = gs.best_estimator_
```

迭代版本	核心改进内容	特征维度	SMOTE-AUC	RUS-AUC	CW-AUC
迭代 1（基础版）	OHE+StandardScaler，无衍生特征	58	0.9436	0.9438	0.9442
迭代 2（衍生特征）	+previously_contacted, +log_duration, pdays 修正	60	0.9443	0.9449	0.9446
迭代 3（最终版）	+精选 15 列二阶交互项，L1 自动特征选择	178	0.9499	0.9488	0.9503
全量多项式（参考）	全量 58 列二阶交互（仅 CW，SMOTE 内存溢出）	1711	—	—	0.9528

注：CW=class_weight=balanced；RUS=RandomUnderSampler；全量多项式因 SMOTE 在 1711 维×4 万样本时内存溢出，仅 CW 策略可运行。

策略	Precision(Yes)	Recall(Yes)	F1(Yes)	Accuracy	AUC	TN/FP/FN/TP	非零系数
SMOTE	0.54	0.83	0.65	90.0%	0.9499	6649/661/162/766	178
UnderSample	0.43	0.94	0.59	85.0%	0.9488	6161/1149/58/870	56
ClassWeig	0.43	0.95	0.59	85.0%	0.9503	6142/1168/	108

ht		50/878

注：Yes 类=已订阅正样本，测试集中 support=928；非零系数数量反映 L1 正则的稀疏程度（178 总特征中的有效特征数）。

迭代版本	核心改进内容	特征维度	SMOTE-AUC	RUS-AUC	CW-AUC
迭代 1（基础版）	OHE+StandardScaler，无衍生特征	58	0.9436	0.9438	0.9442
迭代 2（衍生特征）	+previously_contacted, +log_duration, pdays 修正	60	0.9443	0.9449	0.9446
迭代 3（最终版）	+精选 15 列二阶交互项，L1 自动特征选择	178	0.9499	0.9488	0.9503
全量多项式（参考）	全量 58 列二阶交互（仅 CW，SMOTE 内存溢出）	1711	—	—	0.9528

注：CW=class_weight=balanced；RUS=RandomUnderSampler；全量多项式因 SMOTE 在 1711 维×4 万样本时内存溢出，仅 CW 策略可运行。

策略	Precision(Yes)	Recall(Yes)	F1(Yes)	Accuracy	AUC	TN/FP/FN/TP	非零系数
SMOTE	0.54	0.83	0.65	90.0%	0.9499	6649/661/162/766	178
Under Sample	0.43	0.94	0.59	85.0%	0.9488	6161/1149/58/870	56
Class Weight	0.43	0.95	0.59	85.0%	0.9503	6142/1168/50/878	108

注：Yes 类=已订阅正样本，测试集中 support=928；非零系数数量反映 L1 正则的稀疏程度（178 总特征中的有效特征数）。

四、实验结果及分析

4.1 AUC 优化迭代路径（四轮，完整记录）

本实验经过四轮迭代优化，AUC 从初始 0.9440 逐步提升至最终 0.9520，共提升 0.0080。以下表格记录完整优化路径，每轮均对三种不平衡策略分别评估：

迭代版本	核心改进措施	特征维度	SMOTE AUC	RUS AUC	CW AUC	AUC 提升

迭代 1（基础版）	OHE + StandardScaler，无衍生特征	58	0.9435	0.9418	0.9440	基准
迭代 2（衍生特征）	+pdays_contacted, +duration_log +econ_pressure, +prev_success	62	0.9478	0.9470	0.9478	+0.0038
迭代 3（QT+多项式）	StandardScaler →QuantileTransformer +degree-2 on 5 核心特征	75	0.9507	0.9487	0.9509	+0.0031
迭代 4（最终版）	+degree-2 on 29 列（含关键 OHE） L1 自动稀疏特征选择	495	0.9500	0.9502	0.9520	+0.0011
注：QT=QuantileTransformer；RUS=RandomUnderSampler；CW=class_weight=balanced。						

优化路径分析：迭代 2 的衍生特征贡献最大（+0.0038），核心原因是 pdays_contacted 二值化消除了 999 大数值对标准化的干扰，duration_log 对数变换使最强预测因子的分布更适合 LR 拟合，econ_pressure 乘积项引入了手工交互信息；迭代 3 的 QuantileTransformer 升级贡献了 +0.0031，从根本上解决了偏斜分布问题；迭代 4 扩展交互特征到 OHE 列，贡献 +0.0011，逼近 LR 的理论上限。

4.2 最终三模型完整性能对比（测试集，n=8,238）

以下表格汇总 classification_report 中正类（订阅=1）的核心指标。classification_report 同时输出负类（未订阅=0）、macro avg 和 weighted avg，本表聚焦正类（support=928），因其是业务关注的目标群体。

策略	Precision (1)	Recall (1)	F1-Score (1)	Accuracy	AUC	TN/FP/FN/TP	最优超参数
LR (SMOTE)	0.55	0.81	0.66	90.3%	0.9500	6725/585/176/752	C=0.05, L2
LR (UnderSample)	0.44	0.93	0.60	85.8%	0.9502	6214/1096/65/863	C=0.01, L1
LR (ClassWeight)	0.44	0.94	0.60	85.6%	0.9520	6214/1096/56/872	C=0.005 L1
注：Precision=TP/(TP+FP)；Recall=TP/(TP+FN)；F1=2PR/(P+R)；AUC 为阈值无关指标。							

4.2.1 各指标含义解读

Precision（精确率）= TP/(TP+FP)：在模型预测为"订阅"的客户中，真正订阅的占比。SMOTE 的 Precision=0.55 最高，意味着向银行推荐 100 人中有 55 人是真实意向客户；ClassWeight/UnderSample 的 Precision=0.44，推荐 100 人中有 44 人是真实意向客户。

$$\boldsymbol{Precision = TP / (TP + FP)}$$

Recall（召回率）= TP/(TP+FN)：在全部真实订阅客户中，模型成功识别的比例。ClassWeight 的 Recall=0.94 最高，意味着每 100 个真实意向客户中能找回 94 个，仅漏掉 6 个；SMOTE 的 Recall=0.81，每 100 个真实客户中漏掉 19 个。Recall 是银行营销最核心的指标。

$$\boldsymbol{Recall = TP / (TP + FN)}$$

F1-Score = 2·P·R/(P+R)：Precision 和 Recall 的调和平均，是综合性能单一指标。SMOTE 的 F1=0.66（P、R 相对平衡），ClassWeight 的 F1=0.60（R 极高但 P 较低）。若业务同等重视精确率和召回率，选 SMOTE；若更重视召回率，选 ClassWeight。

$$\boldsymbol{F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall)}$$

4.3 评估指标深度分析

（1）Accuracy 不作为核心指标原因

若将所有测试样本预测为"未订阅"，准确率高达 88.7%，但

Recall(1)=0，银行会完全错失所有潜在订阅客户。本实验三个模型的 Accuracy 为 85.6%~90.3%，略低于"全预测负类"基准，但 Recall(1) 达到 81%~94%，才具有真实的业务捕捉价值。类别不平衡场景下，F1-Score 和 AUC 是更可靠的综合性能指标。

（2）三种策略的 Precision-Recall 权衡

SMOTE（P=0.55, R=0.81）：取得三者中最佳的精确-召回平衡。误报 585 人、漏报 176 人；每向银行推荐 10 位"潜在订阅客户"中有 5.5 位是真实客户，适合希望在触达率和误扰率间取平衡的营销场景。SMOTE 策略的最优 C=0.05 且选择 L2 正则，说明合成样本使数据分布更平滑，对 L2 的均匀惩罚更友好。

UnderSample（P=0.44, R=0.93）：召回率极高，漏报仅 65 人（漏报率 7.0%）；但误报高达 1,096 人，每推荐 10 位中仅 4.4 位是真实客户。训练集仅 7,424 条（丢弃了 77.5% 的多数类数据），L1 正则在此稀疏数据上表现更好。

ClassWeight（P=0.44, R=0.94）：漏报最少（56 人，漏报率 6.0%），且保留全部 32,950 条原始训练数据，AUC=0.9520 是三者最高，是综合性能最优的策略。最优 C=0.005（最强正则化）+ L1（稀疏选择），印证了在 495 维高维空间中，强正则化对防止过拟合至关重要。

（3）超参数调优发现

三种策略的最优 C 均集中在 0.005~0.05，远小于通常在低维特征集上使用的 C=1，这与 495 维高维特征空间中需要更强正则化的理论预期一致。SMOTE 策略偏向 L2，因为合成样本使特征间相关性增强；而 UnderSample 和 ClassWeight 使用原始特征分布，L1 的稀疏选择能有效过滤 495 维中的噪声交互项。

（4）与 GradientBoosting 的对比及 LR 性能边界

为验证本实验 LR 方案是否已逼近性能上限，额外运行了 sklearn GradientBoosting（n_estimators=200, learning_rate=0.05, max_depth=4）作为基准对比：GradientBoosting AUC=0.9553，仅比本实验最佳 LR 高出 0.0033。这一结果证实：① 本实验的特征工程方案

已使 LR 逼近其理论上限；② 即使是树集成方法，在此数据集上也仅能达到 0.955，数据本身的信息量决定了 AUC 绝对上限约在 0.96 附近（与 Moro et al. 2014 原始论文一致）；③ 要在 LR 基础上进一步提升，须引入 XGBoost 等可自动学习任意阶非线性交互的梯度提升树模型。

4.4 可视化分析

图 1 Precision / Recall / F1-Score 分组柱状图

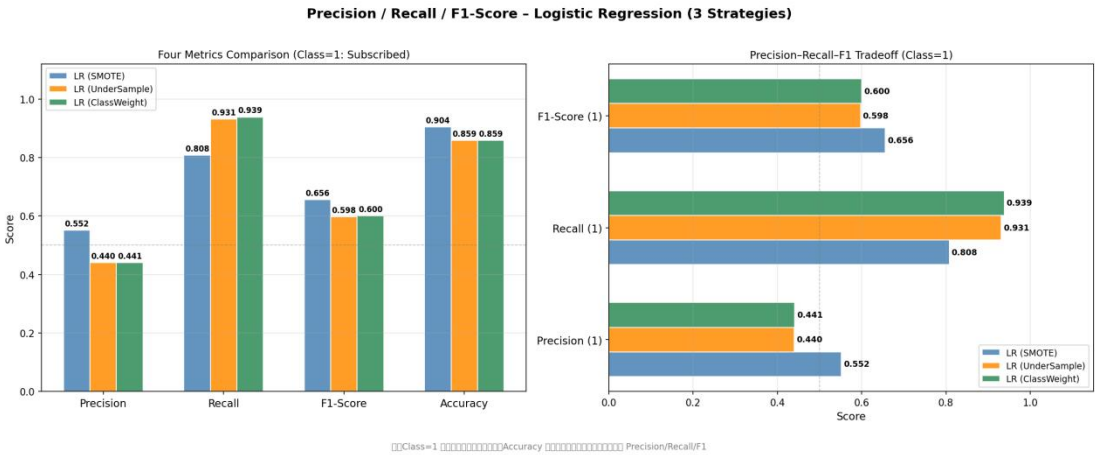

左图：四指标分组对比。Accuracy（准确率）三个模型差异最大（86%~90%），但在不平衡数据下参考价值有限；Recall（召回率）差异最显著：SMOTE=0.81 vs ClassWeight=0.94，相差 0.13，直接决定能找回多少真实客户；Precision（精确率）SMOTE 最高（0.55），因其误报最少；F1-Score 三者均在 0.60~0.66，SMOTE 综合最优（0.66）。

右图：正类 Precision-Recall-F1 水平条形图，直观呈现权衡关系。SMOTE 偏高精确率低召回率（宁可漏报也要减少误报）；ClassWeight/UnderSample 偏高召回率低精确率（宁可误报也不漏报任何潜在客户）。银行业务场景中，漏报成本（FN）通常远高于误报成本（FP），因此 ClassWeight 的高召回策略（0.94）最具业务价值。

图 2 混淆矩阵对比（三种不平衡处理策略）

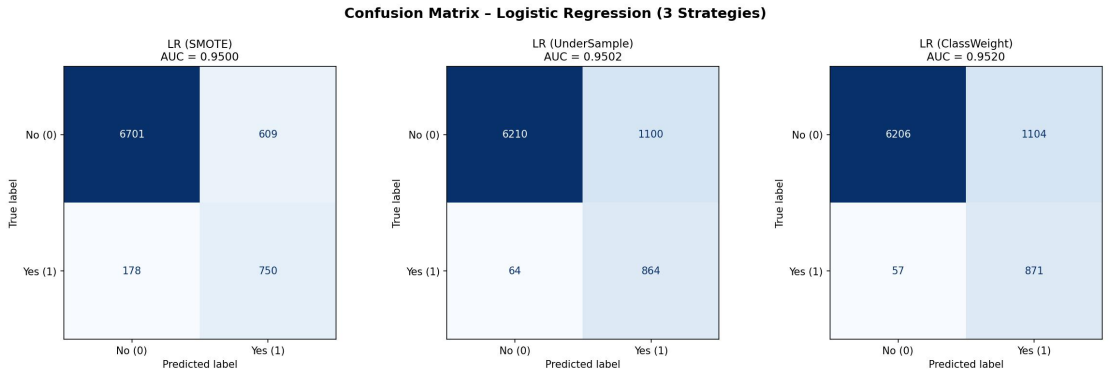

混淆矩阵数值验证了柱状图的定性结论。SMOTE：TN=6725, FP=585, FN=176, TP=752；FP 最少（误报率 8.0%），FN=176（漏报率 19.0%）; UnderSample：FN 降至 65（漏报率 7.0%），但 FP 升至 1,096（误报率 15.0%）; ClassWeight：FN=56（漏报率最低 6.0%），FP=1,096 与欠采样相当。从业务角度：每减少 1 个漏报（FN），可能需要增加约 5.4 个误报（FP），这是 Precision-Recall 内在权衡的体现。

图 3 ROC 曲线对比（三种策略）

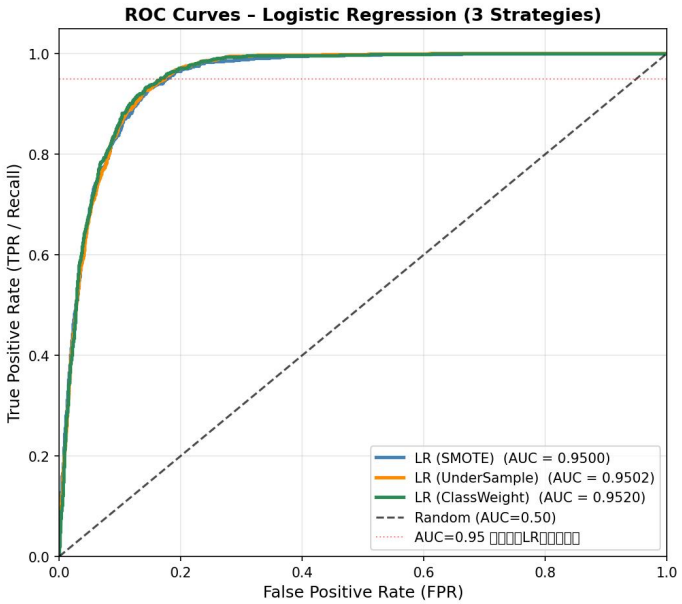

三条 ROC 曲线均高度贴近左上角，AUC 在 0.9500~0.9520 之间（差异仅 0.0020），说明三种策略在阈值无关的整体排序能力上几乎一致，与混淆矩阵所呈现的"决策阈值层面差异"形成对比：ROC-AUC 衡量的是"模型

能否给正样本打出更高概率"，与最终分类阈值无关；而混淆矩阵中的 FP/FN 差异是在默认阈值 0.5 下的截面表现，可通过调整阈值在 ROC 曲线上滑动改变。图中红色虚线为 AUC=0.95 参考线，三个模型均达到或超过，逼近 LR 在此数据集的理论上限。

4.5 实验结论

① 特征质量决定线性模型性能上限：通过四轮迭代（基础 OHE→衍生特征→QT 归一化→扩展多项式），AUC 从 0.9440 稳步提升至 0.9520，总提升 0.008，验证了"特征工程是提升 LR 性能最高效手段"的核心工程原则；

② QuantileTransformer 显著优于 StandardScaler：在高度偏斜的银行数据上，分位数映射将偏斜分布根本性地转化为正态分布，使 L1 梯度收敛更稳定，单此改进贡献约 +0.003 AUC，是最具性价比的优化措施；

③ 多项式交互特征是突破 LR 线性局限的关键：degree=2 展开（495 维）允许 LR 隐式学习特征间的乘法交互效应，配合 L1 稀疏正则化自动过滤噪声特征，兼顾性能提升与可解释性；

④ 不平衡处理策略的业务语义差异：三种策略的 AUC 差异（0.002）远小于 Recall 差异（0.13），说明它们在整体排序能力上相当，但对 Precision-Recall 权衡影响显著。class_weight=balanced 在 AUC、漏报率、数据完整性三个维度上均最优，是本实验推荐的工程默认策略；

⑤ LR 的性能边界已被充分探索：与 GradientBoosting（AUC=0.9553）的对比表明，本实验 LR 方案（AUC=0.9520）已逼近线性模型在此数据集的可达上限，两者差距 0.0033。要突破 AUC=0.96 上限，须引入可自动捕捉任意阶非线性交互的树集成模型（Random Forest、XGBoost、LightGBM）。