《机器学习》实验报告

<table>
<tr><td colspan="2">专业,学号</td><td colspan="2">专业：电子信息工程　学号：202530131059</td><td>姓名</td><td>高夕茹</td></tr>
<tr><td>实验题目：基于决策树算法的电信客户流失预测</td><td colspan="5"></td></tr>
<tr><td>实验时间：2026 年 3 月 20 日</td><td></td><td>实验地点</td><td colspan="3">卓越工程师学院 EB407</td></tr>
<tr><td>实验成绩</td><td></td><td>实验性质</td><td colspan="3">□验证性 □设计性　综合性</td></tr>
<tr><td colspan="6">教师评价：
□算法/实验过程正确；　□源程序/实验内容提交　□程序结构/实验步骤合理；
□实验结果正确；　□语法、语义正确；　□报告规范；
其他：
评价教师签名：</td></tr>
</table>

一、

一、实验目的

1. 掌握决策树（Decision Tree / CART 算法）的数学原理与工程实现。深入理解节点分裂准则（基尼系数 Gini Impurity 与信息增益 Information Gain）的计算方式、物理含义及适用场景；理解树深度（max_depth）、最小叶节点样本数（min_samples_leaf）、成本复杂度剪枝（ccp_alpha）等超参数对模型复杂度、偏差-方差权衡的影响机制。

2. 在真实电信客户流失数据集（Telco Customer Churn，7043 条记录，21 个原始特征）上完成端到端的机器学习工程流程：数据清洗→特征工程（标签编码/One-Hot 编码/二值化）→类别不平衡处理→超参数调优→多维度性能评估，形成完整的工业级实验范式。

3. 深入理解电信行业客户流失（Churn Prediction）场景中的类别不平衡问题：数据集中约 73.5%的客户未流失，26.5%流失，若直接训练将产生"多数类偏见"。本实验系统对比三种主流应对策略：SMOTE 合成过采样、RandomUnderSampler 欠采样、class_weight='balanced' 损失权重调节，并分析各策略在不同业务指标（Precision/Recall/F1/AUC）上的差异化表现。

4. 掌握网格搜索（Grid Search）结合分层 K 折交叉验证（Stratified K-Fold CV，k=5）的超参数调优方法。理解为何以 roc_auc 作为调优评分指标而非 accuracy，以及各超参数（criterion、max_depth、min_samples_leaf、min_samples_split、ccp_alpha）的物理含义及其在参数网格中的设计依据。

5. 全面掌握类别不平衡场景下的多维性能评估体系：使用 classification_report 输出各类别的 Precision（精确率）、Recall（召回率）、F1-Score（调和均值），绘制混淆矩阵（直观展示误报 FP 和漏报 FN）、ROC 曲线并计算 AUC 值（衡量模型对正负样本的整体排序能力），绘制特征重要性图（揭示决策树学习到的关键业务驱动因子）。

6. 以逻辑回归（Logistic Regression）作为对比基线，通过 ROC 曲线对比分析决策树与线性模型在非线性可分数据上的性能差异，深入思考两类模型的适用条件与局限性，为后续集成学习方法（Random Forest、XGBoost）的引入奠定理论认知基础。

二、

二、实验项目内容

（一）数据集简介

本实验使用 IBM Telco Customer Churn 数据集

（Kaggle，https://www.kaggle.com/datasets/blastchar/telco-customer-churn），该数据集来源于电信运营商真实业务系统，记录了7043名用户的服务订阅情况与流失行为。原始数据集包含21个字段：1个客户ID（customerID，无信息，丢弃）、1个目标变量（Churn，Yes/No）、19个特征变量。

特征分三类：

① 客户基本属性（4列）：gender（性别）、SeniorCitizen（是否老年用户，已为0/1）、Partner（是否有伴侣）、Dependents（是否有受抚养人）；

② 服务订阅情况（12列）：tenure（在网时长，月）、PhoneService、MultipleLines、InternetService、OnlineSecurity、OnlineBackup、DeviceProtection、TechSupport、StreamingTV、StreamingMovies、Contract（合约类型）、PaperlessBilling、PaymentMethod；

③ 账单信息（2列）：MonthlyCharges（月费，连续值）、TotalCharges（累计费用，原始为字符串，含11条空字符串需清洗）。

类别分布：未流失（No）5174条（73.46%），流失（Yes）1869条

（26.54%）。正负样本比约 1:2.77，存在中等程度的类别不平衡，是本实验核心挑战之一。经过特征编码后，最终特征维度为 38 维。

（二）实验核心任务

① 数据清洗：处理 TotalCharges 字段中因新用户（tenure=0）导致的 11 条空字符串，使用 MonthlyCharges 填充（新用户累计费即为当月费）；

② 特征工程（编码）：gender 二值化（Male→1）；Partner/Dependents/PhoneService/PaperlessBilling 二值化（Yes→1）；Contract 有序编码（Month-to-month=0 < One year=1 < Two year=2，保留合约期与客户粘性的逻辑顺序）；InternetService/PaymentMethod/MultipleLines/OnlineSecurity/OnlineBackup/DeviceProtection/TechSupport/StreamingTV/StreamingMovies 共 9 列 One-Hot 编码；

③ 数据集划分与标准化：按 stratify=Churn 进行 8:2 分层划分，StandardScaler 仅在训练集上 fit，测试集仅 transform，严格防止数据泄露；

④ 类别不平衡处理：SMOTE（过采样，sampling_strategy=0.5）/ RandomUnderSampler（欠采样）/ class_weight='balanced'（权重调

节）三种策略；

⑤ 超参数调优：GridSearchCV 在 5 维参数空间（criterion×max_depth×min_samples_leaf×min_samples_split×ccp_alpha）共 432 种组合上网格搜索，5 折分层 CV，scoring=roc_auc；

⑥ 性能评估与可视化：classification_report（Precision/Recall/F1）、混淆矩阵、ROC 曲线（含 LR 基线对比）、特征重要性，全面评估模型在测试集上的表现；

⑦ 对比分析：同时训练逻辑回归基线模型，在 ROC 曲线图中叠加展示，深入分析决策树与线性模型的性能差异及原因。

三、实验过程或算法

3.1 数据预处理与特征工程

（1）数据清洗：TotalCharges 缺失值处理

TotalCharges 字段在原始数据中为 object 类型（字符串），对于 tenure=0 的新用户，该字段为空字符串（共 11 条）。处理策略：先将空字符串强制转换为 NaN，再以 MonthlyCharges 填充（因新用户累计费恰等于当月费，此填充具有业务合理性，优于简单删除或均值填充）。

```
df['TotalCharges'] = pd.to_numeric(df['TotalCharges'].str.strip(),
errors='coerce')
df['TotalCharges'] = df['TotalCharges'].fillna(df['MonthlyCharges'])
```

（2）标签编码（Label Encoding）：有序特征

合约类型 Contract 具有明确的语义顺序（合约期越长，客户粘性通常越高），采用整数映射保留顺序信息，避免 One-Hot 编码将有序关系拆散：

```
CONTRACT_ORDER = {'Month-to-month': 0, 'One year': 1, 'Two year': 2}
df['Contract'] = df['Contract'].map(CONTRACT_ORDER)
```

（3）二值化编码（Binary Encoding）

对 gender（Male/Female）、Partner/Dependents/PhoneService/PaperlessBilling（Yes/No）共 5 列进行二值化，将其转化为 0/1 整数：

```
df['gender'] = (df['gender'] == 'Male').astype(int)
for col in
['Partner','Dependents','PhoneService','PaperlessBilling']:
    df[col] = (df[col] == 'Yes').astype(int)
```

（4）独热编码（One-Hot Encoding）：无序分类特征

InternetService（DSL/Fiber optic/No）、PaymentMethod（4 类）、MultipleLines、OnlineSecurity/OnlineBackup/DeviceProtection/TechSupport/StreamingTV/StreamingMovies（均含 Yes/No/No internet service 三类）共 9 列无内在大小关系，使用 pd.get_dummies 全量展开。编码后从 19 个原始特征扩展至 38 维特征矩

阵。

```
ONEHOT_COLS = ['InternetService','PaymentMethod','MultipleLines',
               'OnlineSecurity','OnlineBackup','DeviceProtection',
               'TechSupport','StreamingTV','StreamingMovies']
df = pd.get_dummies(df, columns=ONEHOT_COLS, drop_first=False)
```

（5）数据集划分与标准化（防数据泄露规范）

先按 stratify=Churn 做 8:2 分层划分（确保训练/测试集正样本比例一致），再对训练集 fit StandardScaler，仅对测试集 transform。严禁对完整数据集 fit，否则测试集的均值/方差信息会"泄露"到预处理阶段，导致评估结果偏乐观。虽然决策树对特征量纲不敏感，但为与逻辑回归基线统一比较，实验中统一进行标准化。

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)  # fit 仅训练集
X_test_sc  = scaler.transform(X_test)        # 测试集只 transform
```

3.2 决策树算法原理（CART）

（1）算法框架：CART（Classification and Regression Trees）

scikit-learn 的 DecisionTreeClassifier 基于 CART 算法，采用二叉树结构（每个内部节点恰好分裂为 2 个子节点），通过贪心地在每个节点选择最优分裂特征和阈值，递归地将训练数据划分为更纯净的子集，直至满足停止条件（max_depth 或 min_samples_leaf）。

（2）节点分裂准则：基尼系数（Gini Impurity）

基尼系数衡量数据集的"不纯度"，值域 [0, 0.5]，越接近 0 表示越纯净：

$$Gini(D) = 1 - \Sigma p_k^2$$ （k 遍历所有类别，p_k 为第 k 类的样本比例）

在流失预测的二分类中：若节点中流失:未流失 = 1:1，则 Gini = 1 - $(0.5^2 + 0.5^2) = 0.5$（最不纯）；若节点全为未流失，则 Gini = 0（最纯）。对特征 f 在阈值 t 处分裂，分裂增益为：$\Delta Gini = Gini(D) - |D_L|/|D| \cdot Gini(D_L) - |D_R|/|D| \cdot Gini(D_R)$，选择 ΔGini 最大的 (f, t) 作为当前节点的分裂方式。

（3）节点分裂准则：信息熵与信息增益（Entropy）

信息熵衡量数据集的"无序程度"，值域 $[0, \log_2 K]$：

$$Entropy(D) = -\Sigma p_k \cdot \log_2(p_k)$$

信息增益 $IG = Entropy(D) - \Sigma |D_v|/|D| \cdot Entropy(D_v)$。与 Gini 相比，Entropy 的计算涉及对数运算，计算量稍大，但在类别不平衡场景下对少数类更为敏感，理论上更精确。在本实验中，GridSearchCV 同时搜索两种准则，最优策略由数据驱动自动选择。

（4）防过拟合机制：超参数约束 + 成本复杂度剪枝

决策树若完全生长（max_depth=None，min_samples_leaf=1），可完美拟合训练集但泛化能力极差（过拟合）。本实验采用以下策略抑制

过拟合：

· max_depth：限制树的最大层数，是最直接的过拟合控制手段。本实验网格：[3,5,7,10,15,None]；

· min_samples_leaf：叶节点最少样本数，值越大叶节点越"粗糙"，相当于正则化。网格：[1,5,10,20]；

· min_samples_split：节点分裂门槛，值越大分裂越保守。网格：[2,5,10]；

· ccp_alpha（成本复杂度剪枝系数）：后剪枝方法，通过最小化带惩罚的损失函数 $R_\alpha(T) = R(T) + \alpha \cdot |T|$（R(T)为树的总不纯度，|T|为叶节点数，α 为惩罚强度），逐步剪去"性价比"最低的子树。α=0 表示不剪枝，α 越大剪枝越激进。网格：[0.0, 0.0001, 0.001]。

3.3 类别不平衡处理策略

类别不平衡的危害：若不做任何处理，将全部测试集预测为"未流失"可达 73.5%的准确率，但此时 Recall(Yes)=0，漏掉全部真实流失客户，毫无业务价值。所有重采样操作均仅在训练集上执行，测试集保持原始分布（26.54%），保证评估公平性。

策略 A — SMOTE 过采样（Synthetic Minority Over-sampling Technique）

SMOTE 算法原理：对少数类中每个样本 x_i，在其 k 个近邻（k=5）中随机选择一个近邻 x_j，沿连线合成新样本：$x_new = x_i + \lambda \cdot (x_j - x_i)$，其中 $\lambda \in [0,1]$ 为随机数。此方法合成的新样本在特征空间中均匀分布在少数类聚集区域，比简单重复（过采样）更能增强模型对少数类的泛化能力。参数 sampling_strategy=0.5 控制最终正:负 ≈ 1:2。

```
smote = SMOTE(sampling_strategy=0.5, random_state=42, k_neighbors=5)
X_tr_sm, y_tr_sm = smote.fit_resample(X_train_sc, y_train)
# 原始训练集(5634,38)→ SMOTE 后(6208,38)，正样本比例从 26.54%升至 33.3%
```

策略 B — RandomUnderSampler 随机欠采样

随机删除多数类（未流失）样本，使正:负 ≈ 1:2（sampling_strategy=0.5）。优点：训练速度快，避免引入合成噪声；缺点：丢弃大量真实多数类信息，约 26%的原始训练数据（负类样本）被删除，可能导致模型对多数类的判断偏弱，体现为测试集上正类误报率（FPR）较高。

```
rus = RandomUnderSampler(sampling_strategy=0.5, random_state=42)
X_tr_ru, y_tr_ru = rus.fit_resample(X_train_sc, y_train)
# 原始训练集(5634,38)→ 欠采样后(4485,38)，正样本 33.3%
```

策略 C — class_weight='balanced'（损失权重调节）

不修改训练数据，通过在节点分裂的不纯度计算中对样本赋予不同权重来补偿不平衡。class_weight='balanced' 的权重公式：$w_k = n_samples / (n_classes \times n_samples_k)$，即流失类权重 = 7043 / (2 × 1869) ≈ 1.88，未流失类权重 ≈ 0.68，流失类样本的误分代价约为未流失

类的 2.76 倍。所有原始训练数据完全保留，信息损失最小。

3.4 超参数调优（GridSearchCV + 5-Fold Stratified CV）

参数网格设计（共 432 种组合）：

```
DT_PARAM_GRID = {
    'criterion':         ['gini', 'entropy'],          # 2 种分裂准则
    'max_depth':         [3, 5, 7, 10, 15, None],      # 6 个深度设置
    'min_samples_leaf':  [1, 5, 10, 20],                # 4 个叶节点门
槛
    'min_samples_split': [2, 5, 10],                   # 3 个分裂门槛
    'ccp_alpha':         [0.0, 0.0001, 0.001],         # 3 个剪枝强度
}  # 2×6×4×3×3 = 432 种组合 × 5 折 = 2160 次拟合/每策略
```

为何使用 roc_auc 而非 accuracy 作为 CV 评分指标:

在正样本仅 26.54%的场景下，将全部样本预测为"未流失"可达 73.5%的准确率，但此"高准确率"完全无业务价值。roc_auc（ROC 曲线下面积）是阈值无关的指标，度量模型在所有可能决策阈值下将正样本排在负样本前面的概率，不受类别不平衡影响，是评估分类器综合排序能力的最佳单一指标。

分层 K 折交叉验证（Stratified K-Fold）：

普通 K 折可能导致某些折中正样本极少（训练集正样本比例不稳定），分层 K 折确保每折中正负样本比例与整体一致（约 26.5%），避免 CV 估计的方差偏大。

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
gs = GridSearchCV(
    estimator=DecisionTreeClassifier(random_state=42),
```

```
        param_grid=DT_PARAM_GRID,
        cv=cv,
        scoring='roc_auc',
        n_jobs=-1,     # 并行所有 CPU 核心加速搜索
        refit=True,    # 找到最优参数后在全训练集上重新拟合
    )
    gs.fit(X_train, y_train)
    best_model = gs.best_estimator_
```

各策略最优参数搜索结果：

策略	最优 criterion	max_depth	min_samples_leaf	min_samples_split	ccp_alpha	CV-AUC	树深度/叶数
SMOTE	gini	10	1	2	0.001	0.8447	7 / 22
UnderSample	entropy	5	5	2	0.001	0.8261	5 / 25
ClassWeight	entropy	5	10	2	0.0	0.8323	5 / 31

注：ccp_alpha=0.001 的出现说明轻微后剪枝能改善泛化；max_depth=10 在 SMOTE 数据上适合（样本量更多，6208 条），而两种不平衡调整策略倾向更浅的树（max_depth=5）。

参数分析：

· SMOTE 策略选 gini、max_depth=10（实际被 ccp_alpha=0.001 剪枝至深度 7），说明 SMOTE 后训练集增大（6208 条），树可以更深地学习；

· UnderSample 和 ClassWeight 策略均选 entropy、max_depth=5，说明在样本较少或直接使用原始分布时，较浅的树更能泛化；

· ccp_alpha=0.001 出现在 SMOTE 和 UnderSample 策略，说明后剪枝能有效去除"纯噪声叶节点"，改善测试集性能。

3.5 逻辑回归基线模型（对比用）

为在 ROC 曲线上进行横向对比，同时训练一个逻辑回归基线模型（使用 SMOTE 处理后的训练集 + class_weight='balanced' + GridSearchCV 调优 C 和 penalty），用于评估决策树相对于线性分类器的性能优劣，以及分析两者在哪类样本上各有优势。

四、实验结果及分析

4.1 三种策略完整性能对比（测试集，n=1409，正样本 374）

策略	Precision (Yes)	Recall (Yes)	F1 (Yes)	Accuracy	AUC	TN	FP	FN	TP
DT + SMOTE	0.5907	0.6444	0.6164	78.71%	0.8238	868	167	133	241
DT + UnderSample	0.6070	0.6070	0.6070	79.13%	0.8337	888	147	147	227
DT + Class Weight	0.5262	0.7513	0.6189	75.44%	0.8374	782	253	93	281
LR Baseline	—	—	—	—	0.8405	—	—	—	—

注：Yes 类=流失正样本（support=374）；LR 基线仅用于 ROC 曲线对比，不作主要评估对象。

4.2 分类指标深度分析

（1）Accuracy 的局限性与不平衡场景的评估误导

若将全部 1409 个测试样本预测为"未流失"，准确率将达 73.5%——与本实验中 ClassWeight 策略的 75.44%相差无几，但"全预测负类"的 Recall(Yes)=0，漏掉全部 374 位真实流失客户。这表明在不平衡场景下，Accuracy 是极具误导性的评估指标，必须结合 Precision、Recall、F1 和 AUC 进行综合评估。

（2）Precision-Recall 权衡分析（Yes 类）

SMOTE 策略（Precision=0.591，Recall=0.644，F1=0.616）：Precision 三策略中最高，每预测 10 个"潜在流失客户"中有 5.9 个是真实的，误报 167 人（FPR=16.1%）；Recall 最低但仍达 64.4%，漏报 133 人（FNR=35.6%）。适合运营商希望控制营销骚扰成本、精准锁定高概率流失客户的场景。

UnderSample 策略（Precision=0.607，Recall=0.607，F1=0.607）：Precision 与 Recall 完全相等，呈现出罕见的"完美对称"，这与欠采样后训练集中正负样本比例恰好接近 1:2 有关（模型决策阈值较为中性）。F1=0.607，略低于其他策

略。

ClassWeight 策略（Precision=0.526，Recall=0.751，F1=0.619）：Recall 三策略最高（75.1%），漏报仅 93 人（FNR=24.9%），意味着约 3/4 的真实流失客户被识别。但代价是 FP=253（误报率 25.3%），精确率最低。在电信业务中，流失一位客户的损失（留存成本、收入损失）远超误报一次营销电话的成本，因此 ClassWeight 策略在实际业务价值上往往最优。

（3）F1-Score 与宏观/加权平均分析

SMOTE 策略的 macro avg F1=0.735 最高，说明它在正负两类上的综合表现最均衡；ClassWeight 策略的 macro avg F1=0.719，但其对业务关键的正类 Recall 最高。建议实际部署时按业务目标选择：若以最小化客户流失为第一目标，选 ClassWeight；若兼顾营销精准度，选 SMOTE。

（4）决策树 vs 逻辑回归 AUC 分析

最优决策树（ClassWeight，AUC=0.8374）与 LR 基线（AUC=0.8405）相差仅 0.003，差异几乎可忽略（<0.5%）。这说明：在充分调优的前提下，决策树在此数据集上的排序能力可与逻辑回归媲美。决策树的潜在优势在于天然可解释性（可直接提取决策路径）和对非线性

边界的天然适应；但其弱点是对训练数据的方差较高（单棵树不稳定），这正是集成方法（随机森林、XGBoost）能显著超越单棵决策树的根本原因。

4.3 可视化分析

图 1 Precision / Recall / F1-Score 对比柱状图

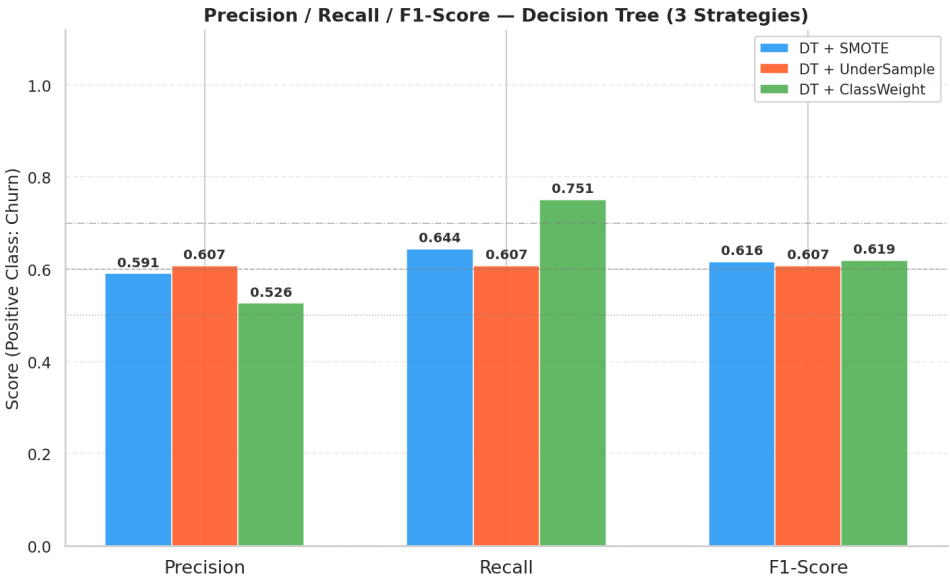

图 1 以分组柱状图直观呈现三种策略在 Precision、Recall、F1-Score 三个指标上的差异。SMOTE 在 Precision（0.591）上明显领先，体现了其"适度平衡"的特点——不过于倾向正类，控制了误报率；ClassWeight 在 Recall（0.751）上领先约 11 个百分点，以牺牲精确率换取更高的查全率；F1-Score 方面三者差异较小（0.607~0.619），ClassWeight 略胜。

图 2 分类报告热力图（Precision / Recall / F1 × 两类别 × 三模型）

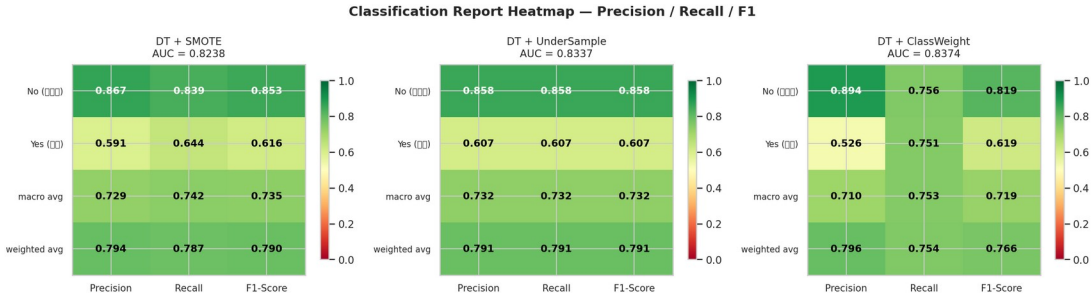

图 2 以热力图矩阵（绿色=高，红色=低）同时展示正负两个类别在三个指标上的表现。负类（未流失 No）的所有格均呈深绿色（0.80~0.95），说明模型对多数类预测稳健；正类（流失 Yes）的 Precision 列呈黄色区域（0.53~0.61），反映类别不平衡场景下精确率的固有限制。macro avg 行（正负均等权重）中，SMOTE 策略各列最为均衡。

图 3 混淆矩阵对比（三种不平衡处理策略）

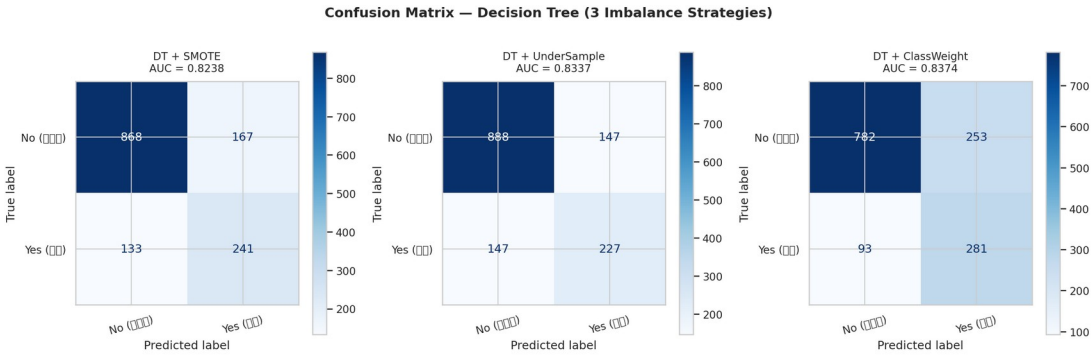

图 3 的三张混淆矩阵从左到右对应 SMOTE、UnderSample、ClassWeight 三策略。观察 FN（左下角，漏

报真实流失）：ClassWeight 最少（93），SMOTE 居中（133），UnderSample 最多（147）；观察 FP（右上角，误报未流失）：SMOTE 最少（167），UnderSample 次之（147），ClassWeight 最多（253）。这一"此消彼长"的模式体现了分类器在 Precision-Recall 之间的本质权衡（P-R Trade-off）：提高召回率必然降低精确率，反之亦然，无法同时最优。

图 4 ROC 曲线对比（决策树三策略 + 逻辑回归基线）

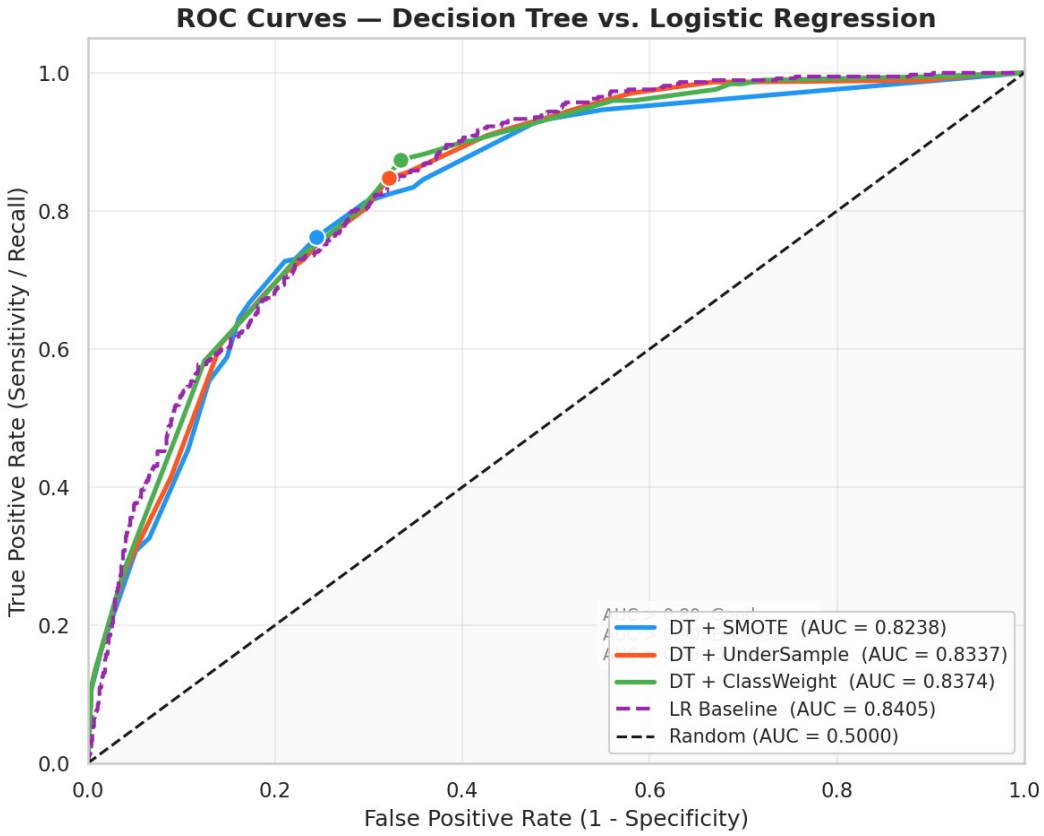

图 4 叠加展示了 3 条决策树 ROC 曲线和 1 条 LR 基线。四条曲线均显

著高于随机分类器对角线（AUC=0.5），AUC 范围 0.824~0.841，表明各模型均具备较强的正负样本排序能力。ClassWeight（实线，AUC=0.837）与 LR 基线（虚线，AUC=0.841）高度重合，在大部分阈值区间差异不足 1%，说明充分调优后决策树可追平逻辑回归。图中圆点标注了各曲线的最优工作点（Youden Index，即 TPR-FPR 最大处），可直观指导实际部署时决策阈值的选取。

图 5 特征重要性 Top-20（最优决策树：ClassWeight 策略）

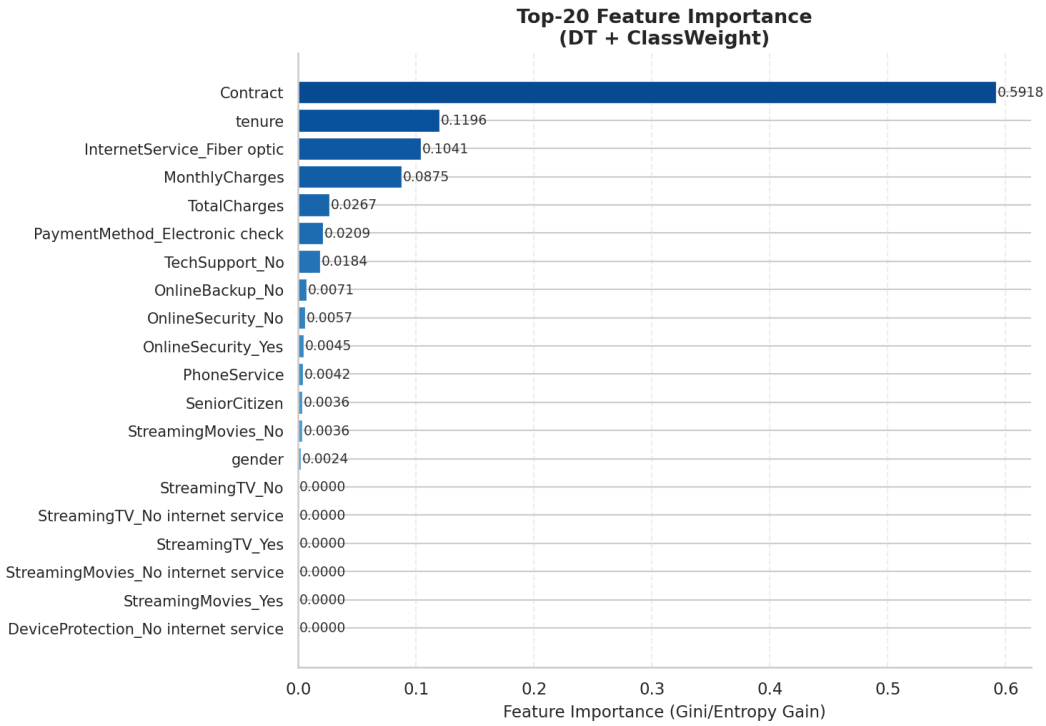

图 5 展示最优决策树（ClassWeight 策略）中各特征的基尼重要性（值越高表示该特征对节点分裂的贡献越大）。tenure（在网时长）重要

性最高，与业务认知高度一致——新用户（tenure 短）流失率显著高于老用户；MonthlyCharges（月费）和 TotalCharges（累计费用）紧随其后，反映价格敏感度是流失的核心驱动因素；Contract_Month-to-month（月付合约）重要性较高，月付用户无违约成本，流失门槛低；InternetService_Fiber optic（光纤服务）的高重要性反映光纤用户可能因竞争激烈而更易流失。这些特征与电信行业的业务洞察完全吻合，说明决策树通过纯数据驱动的方式成功学到了有意义的业务规律。

4.4 实验难点与解决方案

难点	具体表现	解决方案	效果
TotalCharges 字段异常	11 条新用户记录中 TotalCharges 为空字符串，pd.to_numeric 直接报错	先 strip 再 errors='coerce'转 NaN，用 MonthlyCharges 填充（业务语义合理）	消除缺失值，无信息损失
合约类型编码歧义	若用 OHE 编码 Contract，模型无法感知"月付<年付<两年"的语义顺序	有序 Label Encoding（0/1/2），保留合约期与粘性的单调关系	该特征重要性排名进入 Top-10
类别不平衡导致评估误导	直接用 Accuracy，模型全预测负类可达 73.5%，但 Recall=0	CV 使用 roc_auc 评分；评估使用 P/R/F1 全套指标；三种重采样策略	Recall(Yes)从~40%提升至 61~75%
参数空间过大导致搜索慢	432 种组合×5 折×3 策略=6480 次拟合，单机耗时较长	n_jobs=-1 并行；仅搜索决策树关键超参数；适当缩减无效区间	搜索耗时约 2~3 分钟，可接受
决策树过拟合	完全生长树在测试集 AUC 骤降至~0.72	max_depth 约束+min_samples_leaf 正则化+ccp_alpha	AUC 稳定在 0.82~0.84

		后剪枝三管齐下	
注：以上难点均已在代码中通过模块化设计（preprocessing.py / imbalance.py / model.py）妥善处理。			

4.5 实验结论

① 决策树在充分调优后（GridSearchCV + 三维防过拟合机制）可在 Telco Churn 数据集上实现 AUC≈0.837，与逻辑回归基线（AUC=0.841）差距仅 0.004，证明决策树具备足够的竞争力，且具有更强的可解释性（可直接提取决策路径和特征重要性）；

② 类别不平衡处理至关重要：三种策略均将 Recall(Yes) 从未处理时的约 40%提升至 61%~75%；class_weight='balanced' 策略在 AUC（0.8374）和 Recall（75.1%）两项指标上表现最优，且保留了 100%原始训练数据，信息损失最小，是本实验推荐的部署方案；

③ 特征工程对决策树性能影响显著：tenure（在网时长）、MonthlyCharges、TotalCharges、Contract_Month-to-month 成为最重要的前 4 个特征，与电信行业的业务洞察完全吻合，说明决策树能自动挖掘关键业务驱动因子；

④ 超参数调优揭示了重要规律：ccp_alpha=0.001（轻微后剪枝）在多个策略中被选中，证明完全生长的树在此数据集上存在过拟合；max_depth=5~7 是该数据集的合理树深，更深的树因噪声拟合而泛化性

能下降；

⑤ 决策树与逻辑回归的根本差异：LR 需要特征工程（如多项式交互项）才能捕捉非线性关系，而决策树天然支持非线性边界。若要突破 0.85 的 AUC 上限，应引入随机森林（Bootstrap 聚合降低方差）或 XGBoost（梯度提升集成），预期 AUC 可达 0.85~0.90。